

Plataforma Inteligente para Análise e Comparação de Apólices D&O

Relatório Técnico — Projeto Final
Curso InsurMinds · Instituto de Inteligência Artificial Aplicada (I2A2)

Grupo: Squad 4one
Data: 05/10/2026
Licença: MIT

Solução que recebe apólices de Responsabilidade Civil de Administradores em PDF ou imagem, extrai o conteúdo com OCR quando necessário, estrutura as cláusulas com IA Generativa, armazena em banco relacional e produz um quadro comparativo auditável entre apólices.

1. Problema abordado

Comparar duas apólices de D&O é um trabalho manual, lento e dependente de especialista. São documentos longos, redigidos em linguagem jurídica, em que cada seguradora organiza as mesmas informações de maneira diferente: o que uma chama de Limite Máximo de Indenização, outra traz dentro de um quadro de limites; o que uma lista como cobertura, outra concede por cláusula particular. O analista precisa ler os dois documentos inteiros para responder perguntas simples — qual tem maior retroatividade, qual exclui danos morais, qual franquia incide sobre custos de defesa.

O custo disso não é só o tempo. É a assimetria: quem compara às pressas decide com base no prêmio e no limite, que são os campos fáceis de achar, e descobre as diferenças de cláusula no momento do sinistro. A plataforma ataca exatamente esse ponto — transforma documentos heterogêneos em uma ficha padronizada e coloca as divergências lado a lado antes da decisão.

2. Arquitetura da solução

A solução implementa as sete etapas previstas no enunciado como agentes especializados, cada um com responsabilidade única e contrato de dados explícito (classes Pydantic). O orquestrador encadeia os agentes e registra um log passo a passo de cada execução.

PDF / imagem → 1. Recepção → 2. Extração (texto nativo ou OCR) → 3. Estruturação (IA Generativa) → 4. Armazenamento (SQLite) → 5. Comparação (determinística) → 6. Relatório (IA Generativa) → 7. Consulta em linguagem natural

2.1 Descrição dos agentes

Agente	Responsabilidade	Entrada → Saída
1. AgenteRecepcao src/agentes/recepcao.py	Valida formato, tamanho e integridade dos arquivos. Documentos recusados são reportados com o motivo, sem interromper o processamento dos demais.	arquivos → list[DocumentoRecebido]
2. AgenteExtracao src/agentes/extracao.py	Lê o texto nativo com pdfplumber e decide página a página se precisa de OCR (Tesseract). Registra o método usado em cada documento.	documentos → list[TextoExtraido]
3. AgenteEstruturacao src/agentes/estruturacao.py	Núcleo de IA Generativa: envia o texto e um schema ao Gemini e recebe JSON validado com Pydantic, incluindo a evidência textual de cada campo. Sem chave de API, usa extração heurística por rótulos e seções.	textos → list[ApoliceEstruturada]
4. AgenteArmazenamento src/agentes/armazenamento.py	Persiste as fichas em SQLite, com campos escalares consultáveis em SQL e as listas serializadas em JSON na mesma linha. Reprocessar gera nova versão.	fichas → ids no banco
5. AgenteComparacao src/agentes/comparacao.py	Monta o quadro campo a campo, calcula a direção do impacto e apura coberturas e exclusões exclusivas de cada apólice por sobreposição de termos.	fichas → Comparativo
6. AgenteRelatorio src/agentes/relatorio.py	Escreve o sumário executivo a partir das divergências já apuradas — nunca do documento original.	Comparativo → Comparativo + sumário
7. AgenteConsulta src/agentes/consulta.py	Responde perguntas em linguagem natural usando as fichas estruturadas como contexto, citando a apólice de origem.	pergunta + fichas → RespostaConsulta

3. Justificativa das decisões arquiteturais

A IA extrai e redige; ela não decide

A identificação do evento comparativo — qual limite é maior, qual exclusão existe só em uma apólice — é aritmética e teoria de conjuntos sobre a ficha estruturada, e foi implementada de forma determinística. Se o LLM decidisse isso, duas execuções sobre os mesmos documentos poderiam divergir, e nenhuma delas seria auditável. O modelo faz o que só ele faz bem: ler linguagem jurídica heterogênea e devolver campos padronizados, e depois escrever o resumo a partir de diferenças já apuradas.

Saída estruturada com validação, não texto livre

O prompt de extração exige JSON aderente a um schema explícito, e a resposta passa por validação Pydantic antes de entrar no banco. Uma resposta fora do contrato falha na validação em vez de virar dado silenciosamente errado — e o sistema cai para a extração heurística, registrando isso na ficha.

Evidência obrigatória por campo

Para cada campo preenchido, o modelo devolve o trecho literal do documento que sustenta o valor. É o que permite ao analista auditar a extração sem reler a apólice inteira, e é também o mecanismo que torna a alucinação visível: um valor sem trecho correspondente é um sinal de alerta, não um dado.

OCR decidido por página, não por documento

Apólices reais misturam páginas digitais com anexos escaneados. Rodar OCR no documento inteiro desperdiça tempo e degrada o texto de páginas que já tinham camada nativa; não rodar perde o anexo. A decisão por página resolve os dois casos, e o método efetivo fica registrado porque texto de OCR tem qualidade inferior e isso precisa ser visível.

Banco relacional em vez de arquivo

SQLite dá consulta por campo e histórico de versões sem exigir servidor, mantendo o protótipo executável com um clone e um pip install. Listas (coberturas, exclusões) ficam em JSON na mesma linha: para o volume de um MVP isso basta e evita cinco tabelas de apoio que não agregariam à demonstração.

Degradação controlada em vez de falha

Sem chave de API, sem Tesseract ou sem rede, a solução continua executável com capacidade reduzida e informa qual caminho usou. Isso é o que permite demonstrar o fluxo completo em qualquer máquina — e é também o comportamento correto em produção, onde um provedor fora do ar não pode derrubar a plataforma inteira.

4. Tecnologias utilizadas

Camada	Tecnologia	Papel na solução
Linguagem	Python 3.11+	Base de toda a aplicação.
Leitura de documentos	pdfplumber, pdf2image, Pillow	Extração de texto nativo e rasterização de páginas para OCR.
OCR	Tesseract (pytesseract), idioma por	Leitura de apólices digitalizadas ou fotografadas.
IA Generativa	Google Gemini via LangChain	Estruturação das cláusulas, sumário executivo e consulta em linguagem natural.
Contratos de dados	Pydantic v2	Schema da ficha da apólice e validação da saída do modelo.
Persistência	SQLite	Armazenamento estruturado e consulta SQL.
Interface	Streamlit	Demonstração do fluxo etapa por etapa.
Relatórios	ReportLab, python-pptx	Relatório técnico em PDF e pitch deck.
Segredos	python-dotenv	Chaves em .env, fora do versionamento (.gitignore).

5. Fluxo completo de processamento — execução demonstrada

Execução de 05/10/2026 às 09:49:48. **Modo de extração:** IA Generativa (gemini-2.5-flash via LangChain).

Documento	Páginas	Leitura	Caracteres
apolice_do_aurora_digitalizada.pdf	2	OCR	2616
apolice_do_horizonte.pdf	2	texto nativo	2721
apolice_do_meridiano.pdf	2	texto nativo	2083

5.1 Fichas estruturadas

Campo	AURORA SEGURADORA BRASIL S.A. - AUR-DO-2026-8812	HORIZONTE SEGUROS S.A. - DO-2026-004471	MERIDIANO COMPANHIA DE SEGUROS - MD-DO-77.902-3
LMI	25.000.000,00	20.000.000,00	15.000.000,00
Prêmio	231.800,00	184.500,00	142.000,00
Franquia	100.000,00	150.000,00	250.000,00
Base	claims made	claims made	claims made
Retroatividade	Ilimitada	01/03/2019	01/03/2023
Coberturas	11	8	6
Exclusões	5	6	8
Leitura	OCR	texto nativo	texto nativo

6. Comparação entre apólices

12 divergência(s) em 17 campos comparados.

Campo	AURORA SEGURADORA BRASIL S.A.	HORIZONTE SEGUROS S.A.	MERIDIANO COMPANHIA DE SEGUROS
Limite maximo de indenizacao (LMI)	25.000.000,00	20.000.000,00	15.000.000,00
Premio total	231.800,00	184.500,00	142.000,00
Franquia / participacao obrigatoria	100.000,00	150.000,00	250.000,00
Data de retroatividade	Ilimitada	01/03/2019	01/03/2023
Prazo complementar	12 (doze) meses, sem premio adicional	12 (doze) meses, sem cobranca de premio adicional	6 (seis) meses, sem premio adicional
Prazo suplementar	72 (setenta e dois) meses, mediante premio adicional de 150% do premio anual	36 (trinta e seis) meses, mediante pagamento de premio adicional de 75% do premio anual	24 (vinte e quatro) meses, mediante premio adicional de 100% do premio anual
Ambito geografico	Mundial, inclusive Estados Unidos da America e Canada	Territorio nacional brasileiro	Mundial, exceto Estados Unidos da America e Canada
Jurisdicao	Foro da Comarca de Sao Paulo/SP	Foro da Comarca de Sao Paulo/SP, excluidas reclamacoes ajuizadas nos Estados Unidos da America e no Canada	Foro da Comarca do Rio de Janeiro/RJ

6.1 Cláusulas exclusivas de cada apólice

Apólice	Coberturas só nela	Exclusões só nela
AURORA SEGURADORA BRASIL S.A.	Investigacoes e inqueritos, inclusive pre-reclamacao; Obrigacoes trabalhistas e previdenciarias decorrentes de ato de gestao	Responsabilidade contratual assumida por terceiros
HORIZONTE SEGUROS S.A.	Cobertura para investigacoes e inqueritos conduzidos por autoridade competente	Atos dolosos, fraudulentos ou criminosos comprovados por decisao judicial transitada em julgado; Reclamacoes ajuizadas nos Estados Unidos da America e no Canada
MERIDIANO COMPANHIA DE SEGUROS	Extensao a ex-administradores	Danos morais; Reclamacoes relacionadas a questoes ambientais e climaticas; Reclamacoes decorrentes de operacoes de fusao e aquisicao nao comunicadas previamente

6.2 Sumário executivo gerado pela solução

Este resumo compara apólices D&O de AURORA SEGURADORA BRASIL S.A., HORIZONTE SEGUROS S.A. e MERIDIANO COMPANHIA DE SEGUROS. As ofertas divergem em LMI, custos, abrangência geográfica, prazos e escopo de garantias/exclusões, impactando o nível de proteção.

Principais diferenças

- Aurora oferece o maior LMI (R\$ 25.000.000,00) e menor franquia (R\$ 100.000,00) pelo maior prêmio (R\$ 231.800,00). Meridiano apresenta o menor LMI (R\$ 15.000.000,00) e maior franquia (R\$ 250.000,00) pelo menor prêmio (R\$ 142.000,00). Horizonte posiciona-se intermediariamente.
- A data de retroatividade da Aurora é ilimitada. Horizonte e Meridiano possuem datas fixas (01/03/2019 e 01/03/2023).
- O âmbito geográfico da Aurora é mundial, incluindo EUA e Canadá (jurisdição SP). Meridiano cobre

mundialmente, exceto EUA e Canadá (jurisdição RJ). Horizonte restringe a cobertura ao território nacional (jurisdição SP, excluindo EUA/Canadá).

- O prazo suplementar da Aurora é de 72 meses (150% do prêmio), superior aos 36 meses (75%) da Horizonte e 24 meses (100%) da Meridiano. O prazo complementar da Aurora e Horizonte é de 12 meses, contra 6 meses da Meridiano.

- Aurora inclui "Investigações e inquéritos, inclusive pré-reclamação" e "Obrigações trabalhistas e previdenciárias". Meridiano oferece "Extensão a ex-administradores", mas exclui "Danos morais" e "Reclamações ambientais/climáticas". Horizonte exclui "Reclamações ajuizadas nos EUA/Canadá".

Pontos de atenção

O analista deve avaliar o perfil de risco da organização, exposição a litígios internacionais, necessidade de cobertura para ex-administradores e sensibilidade a exclusões (danos morais, ambientais) para determinar a apólice mais alinhada às necessidades da empresa.

Gerado por: IA Generativa (gemini-2.5-flash)

7. Rastreabilidade e dados utilizados

As apólices usadas na demonstração são **fictícias**, criadas especificamente para este trabalho (script `data/gerar_apolices_exemplo.py`). A redação segue a estrutura e a terminologia usuais de condições particulares de D&O no mercado brasileiro — limite máximo de indenização, retroatividade, prazos complementar e suplementar, base claims made —, mas nomes de seguradora, números de apólice, valores e processos SUSEP não correspondem a nenhum produto real. Uma das três é gerada sem camada de texto, simulando um documento digitalizado, para exercitar o caminho de OCR. A plataforma aceita igualmente documentos públicos reais (modelos de apólice publicados por seguradoras ou material da SUSEP).

7.1 Log da execução

```
09:47:32 [Orquestrador] inicio do processamento
09:47:33 [AgenteEstruturacao] cadeia LangChain + gemini-2.5-flash inicializada
09:47:33 [AgenteRecepcao] aceito: apolice_do_aurora_digitalizada.pdf (197 KB)
09:47:33 [AgenteRecepcao] aceito: apolice_do_horizonte.pdf (5 KB)
09:47:33 [AgenteRecepcao] aceito: apolice_do_meridiano.pdf (4 KB)
09:47:33 [AgenteRecepcao] 3 documento(s) apto(s), 0 recusado(s)
09:47:34 [AgenteExtracao] apolice_do_aurora_digitalizada.pdf: 2 pagina(s) sem texto nativo,
acionando OCR
09:47:37 [AgenteExtracao] apolice_do_aurora_digitalizada.pdf: 2 pagina(s), 2616 caracteres (OCR)
09:47:37 [AgenteExtracao] apolice_do_horizonte.pdf: 2 pagina(s), 2721 caracteres (texto nativo)
09:47:37 [AgenteExtracao] apolice_do_meridiano.pdf: 2 pagina(s), 2083 caracteres (texto nativo)
09:48:22 [AgenteEstruturacao] apolice_do_aurora_digitalizada.pdf: 11 cobertura(s), 5 exclusao(oes),
LMI=25000000.0 (IA Generativa (gemini-2.5-flash via LangChain))
09:49:04 [AgenteEstruturacao] apolice_do_horizonte.pdf: 8 cobertura(s), 6 exclusao(oes),
LMI=20000000.0 (IA Generativa (gemini-2.5-flash via LangChain))
09:49:16 [AgenteEstruturacao] apolice_do_meridiano.pdf: 6 cobertura(s), 8 exclusao(oes),
LMI=15000000.0 (IA Generativa (gemini-2.5-flash via LangChain))
09:49:16 [AgenteComparacao] 3 apolices comparadas: 12 divergencia(s) em 17 campos
09:49:48 [AgenteRelatorio] sumario executivo gerado (IA Generativa (gemini-2.5-flash))
09:49:48 [Orquestrador] processamento concluido
```

8. Limitações conhecidas

- A qualidade da extração depende da qualidade do documento: páginas digitalizadas com baixa resolução ou ruído produzem texto degradado, e o erro se propaga para a ficha.
- O extrator heurístico (usado sem chave de API) funciona bem em documentos rotulados e mal em texto corrido jurídico; ele é um recurso de contingência, não uma alternativa equivalente ao modelo.
- A comparação de cláusulas usa sobreposição de termos, não equivalência jurídica: duas redações diferentes com o mesmo efeito legal podem ser apontadas como divergentes.
- A leitura de impacto (quem a diferença favorece) segue regras simples — mais limite é melhor, menos franquia é melhor — e não substitui parecer técnico ou jurídico.
- Não há tratamento de endossos, apólices em múltiplos arquivos, moedas diferentes entre documentos nem conversão cambial.
- O protótipo não implementa autenticação, controle de acesso por usuário nem criptografia dos documentos em repouso — necessários antes de qualquer uso com dados reais de clientes.

9. Possibilidades de evolução futura

- Camada de RAG sobre o texto integral das apólices, permitindo perguntas sobre trechos que não cabem na ficha estruturada, com citação de página.
- Base de cláusulas padrão do mercado para classificar cada redação encontrada como mais restritiva, equivalente ou mais ampla que a referência.

- Registro de concordância humana: o analista confirma ou corrige cada campo extraído, gerando métrica de acurácia por seguradora e por tipo de documento.
- Comparação de versões da mesma apólice ao longo das renovações, destacando o que mudou de um ano para o outro — caso de uso frequente em resseguro.
- Extensão a outros ramos com schema próprio (RC Profissional, Cyber, Riscos Nomeados), mantendo a mesma arquitetura e trocando apenas a ficha.
- Exportação do quadro comparativo em formato de parecer, pronto para anexar à proposta enviada ao cliente.

10. Como executar

```
pip install -r requirements.txt
cp .env.example .env # informe a GOOGLE_API_KEY
python data/gerar_apolices_exemplo.py
streamlit run app.py # interface de demonstração
python main.py --sem-llm # execução offline, extração heurística
```

O repositório é público e está licenciado sob a licença MIT. O README.md traz as instruções completas, a estrutura do projeto e a identificação dos integrantes. A apresentação e o vídeo estão na pasta Projeto_Final_Artefatos.